



ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE  
Fakulta jaderná a fyzikálně inženýrská



# **Těžba dat z experimentů na tokamaku COMPASS**

## **Data mining on the COMPASS tokamak experiments**

Bakalářská práce

Autor:	<b>Matěj Zorek</b>
Vedoucí práce:	<b>Ing. Vít Škvára</b>
Konzultant:	<b>Ing. Jakub Urban, PhD</b>
Akademický rok:	2017/2018



- Zadání práce -

- Zadání práce (zadní strana) -

*Poděkování:*

Chtěl bych zde poděkovat především svému školiteli ..... za pečlivost, ochotu, vstřícnost a odborné i lidské zázemí při vedení mé diplomové práce. Dále děkuji svému konzultantovi ..... za .....

*Čestné prohlášení:*

Prohlašuji, že jsem tuto práci vypracoval samostatně a uvedl jsem všechnu použitou literaturu.

V Praze dne 2. července 2018

Matěj Zorek



## Těžba dat z experimentů na tokamaku COMPASS

*Obor:* Matematické inženýrství

*Druh práce:* Bakalářská práce

*Konzultant:* Ing. Jakub Urban, PhD., Ústav fyziky plazmatu, AV ČR, Za Slovankou 1782/3, 182 00 Praha 8

**Klíčová slova:** klíčová slova (nebo výrazy) seřazená podle abecedy a oddělená čárkou

## Data mining on the COMPASS tokamak experiments

[illegible]

**Key words:** keywords in alphabetical order separated by commas





# Obsah

<b>Úvod</b>	<b>11</b>
<b>1 Teoretická část</b>	<b>13</b>
1.1 HMM . . . . .	13
1.2 K-means . . . . .	13
1.3 Autoregresní model . . . . .	13
1.4 Rysy (Features) . . . . .	13
1.4.1 První a druhá derivace . . . . .	14
1.4.2 Úsekový aritmetický průměr . . . . .	14
1.4.3 Váhový součet zleva . . . . .	15
1.4.4 Úsekový rozptyl . . . . .	15
<b>2 Způsoby vyhodnocení výsledků</b>	<b>17</b>
2.1 Přesnost . . . . .	17
2.2 Správnost . . . . .	17
2.3 Recall . . . . .	17
2.4 F míra . . . . .	17
<b>Závěr</b>	<b>19</b>



# Úvod

Text úvodu....



# Kapitola 1

## Teoretická část

### 1.1 HMM

### 1.2 K-means

### 1.3 Autoregresní model

### 1.4 Rysy (Features)

Ve strojovém učení a rozpoznávání vzorů se pod pojmem "rys" (feature) rozumí individuální měřitelná vlastnost nebo charakteristika pozorovaného jevu. Výběr těchto rysů je naprosto zásadní pro efektivní rozpoznávací, regresní a klasifikační algoritmy. Čím relevantnější a charakterističtější rys, tím lépe jsme schopni docílit větší přesnosti modelu. Na druhou stranu vynechání zbytečných, případně méně důležitých rysů zase snižuje složitost modelu a urychluje jeho trénink. Nejčastější forma rysu je číselná hodnota, avšak při rozpoznávání syntetických vzorků se hojně používají i písmena, slova nebo grafy.

Selekci těchto rysů je možné demonstrovat na následujícím příkladu. Předpokládejme, že bychom chtěli předvídat typ domácího mazlíčka, jež si někdo koupí.

Do rysů můžeme zahrnout například věk osoby, pohlaví, jméno, bydlení (byt, dům, ...), rodinný příjem, vzdělání a počet dětí. Je zřejmé, že většina těchto rysů nám může při předvídání pomoci, ale některé jako třeba vzdělání nebo jméno jsou zjevně méně důležité.

jméno	věk	pohlaví	bydlení	příjem	počet dětí	vzdělání
Karel	25	muž	byt	30.000	0	středoškolské
Petr	30	muž	dům	45.000	2	vysokoškolské
Jana	42	žena	byt	23.000	1	základoškolské
Miloš	51	muž	dům	29.000	1	středoškolské

...

Tabulka 1.1: Vzorová tabulka rysů k demonstračnímu příkladu

### 1.4.1 První a druhá derivace

Jedním ze dvou rysů, jež jsem převzal z již existujícího kódu, je první derivace. Jelikož mám pouze jednotlivé body nemohu používat analytický vzorec na derivace, tedy konkrétně

$$\frac{df(x)}{dx} = f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}. \quad (1.1)$$

Namísto toho ji musím počítat numericky, a to za použití centrální difference druhého řádu pomocí (1.2) a v krajních bodech pomocí jednostranných diferencí prvního nebo druhého řádu (1.3).

$$\hat{f}'_k = \frac{f(x_{k+1}) - f(x_{k-1}))}{2h} \quad (1.2)$$

$$\hat{f}'_0 = \frac{f(x_1) - f(x_0)}{h} \quad \text{a} \quad \hat{f}'_n = \frac{f(x_n) - f(x_{n-1}))}{h} \quad (1.3)$$

Druhým převzatým rysem je druhá derivace, kterou získáme použitím vzorců pro první derivaci na již jednou zderivovaná data.

### 1.4.2 Úsekový aritmetický průměr

Prvním mnou vybraným rysem je úsekový aritmetický průměr naměřených dat, který budu nadále značit jako  $\tilde{X}_m$ . Necht' máme vektor naměřených hodnot  $\mathbf{X} = (x_1, x_2, \dots, x_n)$ , pak definuji úsekový aritmetický průměr pro  $m \in 1, 2, \dots, n$  jako


$$\tilde{X}_m = \frac{1}{w} \sum_{k=m-w}^m x_k, \quad (1.4)$$

kde  $w$  je délka úseku. Pak vektor  $\tilde{\mathbf{X}} = (\tilde{X}_1, \tilde{X}_2, \dots, \tilde{X}_n)$  je rys vektoru  $\mathbf{X}$ .

Ve skutečnosti se jedná o standardní aritmetický průměr (1.5), jež je aplikovaný pouze na úsek dat konečné délky.

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n x_k, \quad (1.5)$$

Mezi rysy jsem ho vybral, protože předpokládám, že okamžitá hodnota je závislá na předchozích datech. Důvod proč využívám jen konečně dlouhý úsek předcházejících hodnot je ten, že ze zákona velkých čísel (standardní) aritmetický průměr konverguje ke střední hodnotě, a tedy ke konstantě. To znamená, že postupem času budou mít rozdílná data v odlišných stavech stejnou hodnotu rysu. Z čehož plyne, že takovýto rys by jen zkresloval a znepřesňoval výsledek, viz Obr. 1.1.



Obr. 1.1: Rozdíl mezi úsekovým a standartním aritmetickým průměrem aplikovaným na syntetická data (pro větší přehlednost je každá křivka zobrazena zvlášť)

### 1.4.3 Váhový součet zleva

Jak jsem se zmínil již dříve, předpokládám závislost na předchozích hodnotách. "Není však překvapením", že hodnoty naměřené s velkým časovým rozestupem na sebe mají mnohem menší vliv, než ty jež jsou naměřeny bezprostředně zasebou. Proto dalším mnou vybraným rysem je tedy váhový součet zleva  $S_m$ .

Nechť  $X = (x_1, x_2, \dots, x_n)$  je vektor naměřených hodnot, pak definuji váhový součet zleva pro  $m \in 1, 2, \dots, n$  jako

$$S_m = \frac{1}{w} \sum_{k=m-w}^m g_{m-k} \cdot x_k, \quad (1.6)$$

kde  $w$  je délka úseku a  $g_m$  je váhová funkce tvaru  $g_m = \gamma^m$ , přičemž  $\gamma \in (0, 1)$ . Pak vektor  $S = (S_1, S_2, \dots, S_n)$  je rys vektoru  $X$ .

### 1.4.4 Úsekový rozptyl

Ve statistice a teorii pravděpodobnosti se pod pojmem rozptyl rozumí střední hodnota kvadrátu odchylky od střední hodnoty náhodné veličiny. Bývá reprezentován symbolem  $Var(X)$  nebo  $\sigma^2$  a definován

vzorcem

$$\text{Var}(X) = E[(X - E[X])^2] \quad (1.7)$$

pro stejně rozdělené diskrétní náhodné veličiny  $X = (x_1, x_2, \dots, x_n)$  můžeme tento vzorec přepsat do tvaru


$$\text{Var}(X) = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{X}_n)^2. \quad (1.8)$$

Když jsem se začínal vybírat rys, které budu potom používat při klasifikaci, byl rozptyl jedna z mých prvních voleb. Naneštěstí je zde stejný problém jako s aritmetickým průměrem a to ten, že s postupem času bude různým stavům přiřazovat stejnou hodnotu. Proto jsem se rozhodl využít namísto standartního aritmetického průměru již dříve definovaný úsekový aritmetický průměr a výslednou veličinu budu dále nazývat úsekovým rozptylem a značit  $D_m$ .

Nechť  $\mathbf{X} = (x_1, x_2, \dots, x_n)$  je vektor naměřených hodnot, pak definuji úsekový rozptyl pro  $m \in 1, 2, \dots, n$  jako

$$D_m = \frac{1}{w} \sum_{k=m-w}^m (x_k - \tilde{X}_m)^2, \quad (1.9)$$

kde  $w$  je opět délka úseku a  $\tilde{X}_m$  je úsekový aritmetický průměr (1.4). Pak vektor  $\mathbf{D} = (D_1, D_2, \dots, D_n)$  je rys vektoru  $\mathbf{X}$ .



Obr. 1.2: Rozdíl mezi úsekovým a normálním rozptylem aplikovaným na syntetická data



## **Kapitola 2**

# **Způsoby vyhodnocení výsledků**

V této kapitole se budu věnovat způsobům jak ohodnotit kvalitu (přesnost) mého algoritmu.

### **2.1 Přesnost**

### **2.2 Správnost**

### **2.3 Recall**

### **2.4 F míra**



# **Závěr**

Text závěru....



# Literatura

- [1] C. M. Bishop, Pattern recognition and machine learning. Springer, New York, 2013.
- [2] M. Kikuchi, K. Lackner, M. Q. Tran, Fusion physics. International Atomic Energy Agency, Vienna, 2012.
- [3] L. R. Rabiner, A tutorial on hidden Markov models and selected applications in speech recognition. Proceedings of the IEEE 77(2), 1989, 257-286.